


MLOPS: MEJORES PRÁCTICAS

Guía Práctica para Proyectos de Machine Learning
A01796363-Arthur Jafed Zizumbo Velasco

1 Código Bien Organizado



Abstracción

- Esconde lo complicado
- Muestra lo necesario
- Fácil de entender

Encapsulación

- Protege datos
- Evita errores
- No valores fijos (hardcodeados X_X)

Modularidad


- Piezas separadas
- Fácil extender
- Reutilizable

Del Notebook a Producción

Evita: Código repetido, copiar-pegar, valores fijos

Objetivo: Código limpio, probado y listo para producción

2 Estructura del Proyecto



Cookie Cutter

- data/** Datos originales
- models/** Modelos guardados
- mlops/** Código pipeline
- tests/** Pruebas automáticas


Estructura consistente

Poetry

- Versiones de librerías
- Archivo lockfile
- Mismo ambiente siempre
- Instalaciones repetibles

Reproduce resultados

3 Seguimiento con MLflow



Organización de Experimentos

1. Experimento

Objetivo (ejemplo, "Clasificar entradas y salidas")

2. Corrida (Run)

Intento con hyper parámetros específicos

3. Versión

Modelo guardado con metadatos

MLflow Tracking

- Guarda parámetros
- Registra métricas
- Almacena modelos
- Compara resultados


Ciclo de Vida

Development: Pruebas | **Staging:** Validación | **Production:** En vivo
| **Archive:** Guardado

Control de Datos

- DVC para datasets
- Saber qué datos usaste
- Repetir experimentos

4 Reproducibilidad



Pipeline FTI

Feature Pipeline

Datos crudos -> Características

Training Pipeline

Características -> Modelo

Inference Pipeline

Nuevos datos -> Predicciones

Mismo proceso siempre

Problemas

Código diferente entre
entrenamiento y producción
Versiones de librerías cambian

Soluciones

Scikit-learn Pipelines
Docker congela ambiente
Seeds fijas en división

5 Pruebas (Testing)



Pruebas Unitarias

Cada parte separada: datos,
características, configuración

Pruebas de Integración

Todo el flujo junto: datos hasta
modelo


Pruebas Diferenciales

¿Nuevo modelo mejor que el
anterior?

Shadow Mode

Prueba en producción sin
afectar usuarios

6 Herramientas Clave



Prefect

Poetry

MLflow

Docker

GitHub


Prefect

- Coordina tareas
- Sabe qué falló
- Reintenta automático
- Escala fácil

Docker

- Empaqueta ambiente
- Mismo en todas máquinas
- Adiós al "funciona en mi máquina"
- Fácil desplegar

7 El Equipo MLOps



Científico de Datos (DS)

Experimenta con modelos. Crea
prototipos. Empieza simple.

Ingeniero de Software (SE)

Código profesional. Limpio, probado
y organizado.

Ingeniero de Datos (DE)

Maneja datos. Limpios y a tiempo.

Ingeniero ML (MLE)

Modelos en pruebas y producción.
MLflow.

Ingeniero DevOps

Infraestructura y monitoreo. Servidores, logs, alertas. Docker, CI/CD

Referencias

- Ahmed, S. (s.f.). Managing Machine Learning Workflows with Scikit-learn Pipelines Part 1: A Gentle Introduction. KDnuggets.
- Amos, D. (2024, 15 de diciembre). Object-Oriented Programming (OOP) in Python. Real Python.
- Anthropic. (2025). Claude 4.5 Sonnet. <https://www.anthropic.com/claude/sonnet>
- Cookiecutter. (2023). Save time and stay consistent. Cookiecutter.
- Galli, S. (2020, 27 de enero). How To Build And Deploy A Reproducible Machine Learning Pipeline. Medium.
- Google DeepMind. (2025). Imagen 4 Ultra. <https://deepmind.google/models/imagen/>
- MLflow. (s.f.). MLflow Tracking. MLflow Docs.
- MLflow. (s.f.). Model Registry Quickstart. MLflow Docs.
- MLflow. (s.f.). Your First MLflow Model: Complete Tutorial. MLflow Docs.
- Onose, E. (2025, 15 de mayo). How to Solve Reproducibility in ML. Neptune Blog.
- Poetry. (s.f.). Introduction | Documentation | Poetry - Python dependency management and packaging made easy. Poetry Documentation.
- Prefect. (s.f.). Introduction. Prefect Documentation.
- scikit-learn. (s.f.). 7.1. Pipelines and composite estimators (Versión 1.7.2). scikit-learn documentation.
- Senthil E. (2023, 10 de marzo). MLOps-Refactoring Python Code. Introduction. Analytics Vidhya. Medium.

Conclusión

MLOps combina buenas prácticas de programación, herramientas de seguimiento y trabajo en equipo. Con estas prácticas, tu modelo de ML será confiable, repetible y fácil de mantener en producción.

Powered by Claude AI (Anthropic) & Imagen 4 (Google DeepMind)